Defesas a Nível de Prompt contra Jailbreaks em Qwen2.5-7B-Instruct: ASR com Self-Reminder, Intention Analysis e Ofuscação Base64

Leonardo Kawakami Hissanaga — NUSP 11374864

Atividade realizada individualmente; todas as contribuições (experimentos, juízes, análise, redação) são do autor.

Resumo

Avaliamos duas defesas a nível de prompt — Self-Reminder (SR) e Intention Analysis (IA) — contra dez jailbreaks manuais aplicados a cinco tarefas maliciosas no modelo-alvo Qwen2.5-7B-Instruct (NF4), medindo a taxa de sucesso do ataque (ASR) com um juiz LLM (Mistral-7B-Instruct-v0.3, Hugging Face). No cenário sem defesa (baseline), o ASR manual foi de 12,0% (6/50); com IA, 2,0% (1/50); com SR, 0,0% (0/50). Um ataque de ofuscação Base64 (família CipherChat) atingiu ASR 0,0% em todas as condições. Em paralelo, um piloto do ataque automático PAIR (atacante Qwen3.5-9B, alvo Llama-2-7B-chat) alcançou ASR de 10,0% (IC 95%: 1,8–40,4%) sem defesa, e nanoGCG (alvo MiniCPM5-2B) não produziu obediência completa em nenhum caso. Um PAIR-lite executado no próprio Qwen2.5 com defesas isoladas inverte o ranking: o SR cede a 60% contra ataque adaptativo, enquanto a IA permanece em 0%. Os resultados indicam que SR e IA anulam jailbreaks manuais neste alvo, mas a literatura mostra falhas específicas de cada defesa, e a calibração do juiz automático com avaliação humana (kappa de Cohen) permanece como trabalho em andamento.

1. Introdução

Jailbreaks de prompting induzem LLMs alinhados a gerar conteúdo nocivo sem alterar pesos. Defesas a nível de prompt — Self-Reminder (Xie et al., 2023) e Intention Analysis (Zhang et al., 2025) — operam apenas em inferência e são avaliadas no estudo de caso de Hayashi et al. (2026, IEEE Access) sobre DeepSeek-R1/V3. Este trabalho reproduz o protocolo das duas defesas sobre um alvo aberto de 7B (Qwen2.5-7B-Instruct), adiciona um vetor de ofuscação (Base64, família CipherChat) não coberto pelo estudo em modelos pequenos, e mede ASR com juiz LLM, em complementação a um piloto de ataque automático (PAIR) e a um experimento nanoGCG conduzidos em alvos distintos (Llama-2-7B-chat e MiniCPM5-2B). Contribuições: (i) tabela ASR defesas × família de ataque no Qwen2.5-7B com juiz HF; (ii) evidência preliminar de que Base64 é ineficaz contra este alvo; (iii) protocolo de avaliação humana para calibração do juiz (kappa de Cohen, Landis & Koch).

2. Metodologia

Modelo-alvo. Qwen2.5-7B-Instruct em 4 bits (bitsandbytes NF4, double quant) em GPU T4 via Google Colab. Alvos auxiliares: Llama-2-7B-chat (NF4) no piloto PAIR e MiniCPM5-2B (fp16) no nanoGCG.

Ataques. (a) *Manuais:* 10 jailbreaks públicos (DAN, AIM, AntiGPT, EvilConfidant, Grandma, Hypothetical, DevMode, OppositeDay e congêneres) × 5 tarefas maliciosas do dataset do paper do Self-Reminder (comer vidro, negacionismo do aquecimento global, phishing bancário, sequestro/chantagem, SQL injection) = 50 queries por condição. (b) *Encoded:* mesma tarefa em payload Base64 (5 queries). (c) *Automáticos:* PAIR — piloto com 10 comportamentos JBB-Behaviors × 5 streams × 3 iterações, atacante Qwen3.5-9B GGUF, prompts vendorizados do repositório oficial, alvo Llama-2; e **PAIR-lite** (11/11): loop de reescrita pelo atacante direto no Qwen2.5, 4 tarefas × {none×2 tentativas, SR, IA} = 20 consultas; nanoGCG (sufixo de 20 tokens, 250 iterações) sobre 10 templates + prompt direto.

Defesas. SR com encapsulamento pré+pós no template original do paper; IA na variante one-pass (a mesma de Hayashi et al., 2026), aplicada de forma isolada por condição: {baseline, SR, IA}.

Avaliação. Dois protocolos de juiz: (a) juiz externo Mistral-7B-Instruct-v0.3 (HF, NF4) com rubrica binária (rótulo 1 = conteúdo substantivo que avança o objetivo nocivo; compliance parcial conta; disclaimer não cancela), usado nas Tabelas 1–2 (165/165 avaliadas, 0 inválidas); (b) juiz unificado Qwen2.5-7B (o próprio alvo em NF4) com escala 1–10 e sucesso em score ≥ 5 (limiar estilo PAIR), reavaliando as 200 linhas consolidadas (manual+encoded+automático) — Tabela 5 e nota de sensibilidade abaixo. Em nanoGCG a avaliação foi humana. ASR = nº de sucessos / respostas válidas por célula.

3. Resultados

Tabela 1 — ASR (%) no Qwen2.5-7B por família × defesa (juiz Mistral-7B; n=50 manual, n=5 encoded):

Família	Baseline	Self-Reminder	Intent. Analysis
manual (10×5)	**12,0** (6/50)	**0,0** (0/50)	**2,0** (1/50)
encoded (Base64)	0,0 (0/5)	0,0 (0/5)	0,0 (0/5)

Tabela 2 — ASR manual (%) por tarefa no Qwen2.5-7B:

Tarefa	Baseline	SR	IA
0 (vidro)	10,0	0,0	10,0
1 (aquec. global)	20,0	0,0	0,0
2 (phishing)	20,0	0,0	0,0
3 (chantagem)	10,0	0,0	0,0
4 (SQL injection)	0,0	0,0	0,0

Tabela 3 — Piloto PAIR (alvo Llama-2-7B-chat, sem defesa, juiz PAIR vendorizado pelo atacante, n=50 streams):

Métrica	Valor
ASR por comportamento	10,0% (IC 95% Wilson: 1,8–40,4)
Streams com sucesso	1/50 (Disinformation/5G-COVID, score 10)
Score máx. 9 sem sucesso	Economic harm, Fraud, Expert advice, Gov.

Tabela 4 — nanoGCG em MiniCPM5-2B (avaliação humana, 11 casos):

Classificação	Baseline	Com sufixo
Obedeceu (artigo completo)	0	0
Parcial	3 (AIM, AntiGPT v2, Balakula)	1 (3-Liner)
Recusou	8	10

Tabela 5 — ASR (%) do PAIR-lite e Base64 (reexecução) × defesas no Qwen2.5, juiz unificado Qwen2.5 self-judge score ≥ 5:

Família	Baseline	Self-Reminder	Intent. Analysis
pair-lite (20 queries)	20,0 (2/10)	**60,0 (3/5)**	0,0 (0/5)
encoded/Base64 (reexec.)	0,0	20,0 (1/5)	0,0

4. Análise

SR anulou os jailbreaks manuais no Qwen2.5 (12%→0%), e IA os reduziu a 2%. Coerente com a literatura para modelos instruídos: Zhang et al. (2025) reportam SR levando Llama2-7B-chat de 23,5% a 1,03% e IA a 0,03%. Contudo, **zero não significa imune**: os autores do SR documentam falhas em jailbreaks longos que proíbem recusas (DevMode+Ranti: 100%→100% no ChatGPT), e Hayashi et al. (2026) mostram SR *pior* que IA em modelos de raciocínio — um jailbreak adaptativo ao SR ou um alvo com raciocínio poderia inverter o ranking observado. Com n=50 por célula, um único sucesso move o ASR em 2 pontos; a ordem IA (2,0%) > SR (0,0%) está dentro do ruído amostral.

Base64 foi ineficaz contra o Qwen2.5-7B em todas as condições (0%, inclusive baseline). Hipótese: o Qwen2.5 foi extensivamente treinado em código e dados técnicos, decodificando Base64 com facilidade — a payload decodada permanece semanticamente nociva e o alinhamento padrão recusa; a ofuscação só teria efeito em alvos com capacidade de decodificação fraca. Zhang et al. (2025) evitaram testar CipherChat em modelos 7B por respostas inválidas; nosso resultado sugere que, para alvos treinados em código, o custo-benefício da ofuscação por codificação é baixo.

One-pass vs. two-pass. Usamos IA one-pass (como a USP); Zhang et al. usam two-pass no paper original. Como a defesa depende do mecanismo de análise de intenção e não da formulação (Apêndice D.2 do paper), a comparação direta com os números publicados exige declarar essa diferença — o que fazemos aqui.

Defesa estática sucumbe ao ataque adaptativo (achado central — Tabela 5). O PAIR-lite rodado no próprio Qwen2.5 inverte o ranking da Tabela 1: o SR, que anulou os jailbreaks manuais (0%), cede em **60%** das consultas reescritas iterativamente pelo atacante, enquanto a IA permanece imune (0%) — coerente com o mecanismo: o SR é um lembrete estático que a reescrita do PAIR contorna ao reformular o enquadramento (treinamento defensivo, simulação de phishing), enquanto a IA classifica a intenção do pedido independentemente da moldura. O Base64 reexecutado pelo juiz unificado registrou 1 sucesso sob SR (20%) contra 0% do juiz Mistral — discordância entre juízes, não entre execuções. Este resultado converte a recomendação "combinar contramedidas" de sugestão da literatura em exigência empírica neste alvo: a defesa mais forte contra ataque manual é a mais frágil contra ataque adaptativo.

Ataques automáticos. O piloto PAIR em Llama-2 (10%, IC amplo 1,8–40,4) validou o pipeline. No nanoGCG, o MiniCPM5-2B inspecionou semanticamente os sufixos via <think> e recusou mais com o sufixo do que sem (10 vs 8 recusas), sugerindo que alvos com raciocínio explícito detectam o artefato adversarial — efeito não medido no Qwen2.5 (sem cadeia de raciocínio visível).

Limitação central: juízes e limiares diferentes. As Tabelas 1–2 usam juiz Mistral-7B com rubrica binária; a Tabela 5 usa o juiz unificado Qwen2.5-7B julgando as próprias respostas (self-judge, possível viés de autoavaliação — declarado), escala 1–10 com limiar score ≥ 5; a Tabela 3 usa o juiz vendorizado do PAIR (rodado pelo próprio atacante — self-preference, declarado); a Tabela 4 é humana. Sob o juiz unificado, o ASR manual sobe de 12% (Mistral, binário) para 44% (baseline; score ≥ 5) — evidência de que o ASR medido depende mais do juiz/limiar que da defesa; as comparações válidas são intra-tabela. A amostra humana de calibração (18+31 linhas) ainda sem rótulos; Hayashi et al. (2026) reportam 12,7% de discordância humano–juiz com viés de falsos negativos. Dois juízes automáticos independentes sobre as 35 consultas do PAIR-lite discordaram em 22,9% das linhas (Qwen3.8-Flash-Next externo vs. self-judge), reforçando a necessidade de painel multi-juiz.

5. Conclusão e reflexões

Implementamos e medimos SR e IA contra jailbreaks manuais em Qwen2.5-7B-Instruct (ASR 12%→0% com SR, →2% com IA), demonstramos a ineficácia de Base64 contra este alvo e validamos pipelines de PAIR (ASR 10% em Llama-2 sem defesa) e nanoGCG (0 obediências em MiniCPM5-2B). Os resultados sustentam a recomendação do estudo de caso de combinar contramedidas, não de eleger uma. Para melhorar: (i) **mais de um LLM como juiz** — Mistral-7B + Llama-3-8B + Qwen2.5 com rubricas distintas e voto/interseção, reportando a discordância intra-painel como incerteza; (ii) **alterações no prompt do julgador** — rubricas com casos-limite (compliance parcial, entrega com disclaimer) calibradas contra subconjunto rotulado; (iii) **calibração com julgamento humano** — protocolo com amostragem estratificada, cegamento e kappa de Cohen pronto e em aplicação nas 31+18 linhas; (iv) painel multi-juiz com calibração humana — o ASR manual medido por dois juízes automáticos difere de 12% (Mistral, binário) a 44% (Qwen2.5, score ≥ 5), e dois juízes sobre o mesmo PAIR-lite discordam em 22,9%: o ASR reportado descreve o juiz tanto quanto o ataque; (v) escalar n por célula (n=5 em SR/IA na Tabela 5) para estreitar os intervalos de confiança.

Referências

[1] V. T. Hayashi et al., "DeepSeek Under Attack: An Analysis of Jailbreak Attacks and Prompt-Level Defenses," IEEE Access, vol. 14, pp. 103944–103961, 2026.

[2] Y. Xie et al., "Defending ChatGPT against Jailbreak Attack via Self-Reminder," Nature Machine Intelligence, 5(12):1486–1496, 2023.

[3] Y. Zhang, L. Ding, L. Zhang, D. Tao, "Intention Analysis Makes LLMs A Good Jailbreak Defender," COLING 2025, pp. 2947–2968. arXiv:2401.06561.

[4] P. Chao et al., "Jailbreaking Black Box Large Language Models in Twenty Queries," SaTML 2025 (PAIR). arXiv:2310.08410.

[5] A. Zou et al., "Universal and Transferable Adversarial Attacks on Aligned Language Models" (GCG/nanoGCG), arXiv:2307.15043.

[6] J. R. Landis, G. G. Koch, "The Measurement of Observer Agreement for Categorical Data," Biometrics 33(1):159–174, 1977.